Detecção de Viés Ideológico em Artigos de Notícias Utilizando Aprendizagem Métrica Profunda e Representações Contextuais

1

Abstract. *This study aimed to investigate ideological bias detection via deep metric learning using the DistilRoBERTa model. It is demonstrated that the use of Contrastive and Triplet Loss with semi-hard sampling optimizes the embeddings space, reaching a Macro F1-Score of* 0.83 *on the ABP dataset. The method proved to be highly competitive, approaching the* 0.84 *mark of the baseline [Volf and Simko 2025], and outperforming LLMs in a zero-shot regime. This approach establishes itself as an efficient alternative for generalization across unseen sources and for mitigating native biases in large models.*

Resumo. *Este estudo teve por objetivo investigar a detecção de viés ideológico via aprendizagem métrica profunda com o modelo DistilRoBERTa. Demonstra-se que o uso de Contrastive e Triplet Loss com semi-hard sampling otimiza o espaço de embeddings, atingindo* 0.83 *de Macro F1-Score no conjunto ABP. O método mostrou-se altamente competitivo, aproximando-se do baseline [Volf and Simko 2025] de* 0.84*, e superando LLMs em regime zero-shot. A abordagem consolida-se como uma alternativa eficiente para generalização em fontes inéditas e mitigação de vieses nativos de grandes modelos*

1. Introdução

Nos últimos anos, a expansão exponencial de informações online via portais de notícias impõe o desafio de assegurar a imparcialidade dos conteúdos. O viés ideológico em artigos pode distorcer a percepção pública e influenciar decisões políticas e resultados eleitorais [Gentzkow and Shapiro 2006, Chiang and Knight 2011]. Dada a subjetividade inerente ao discurso, a identificação automatizada dessa inclinação é uma tarefa complexa, tornando o desenvolvimento de métodos precisos de detecção uma área de pesquisa altamente relevante para a integridade da informação.

No campo do Processamento de Linguagem Natural (PLN), abordagens buscam automatizar essa detecção via conteúdo textual, hiperlinks e teoria da informação [Spinde et al. 2021, Patricia Aires et al. 2019]. Contudo, as soluções atuais frequentemente limitam-se a cenários puramente polarizados ou dependente de fontes externas, os que comprometem a autonomia dos métodos e dificulta a identificação de nuances ideológicas em contextos onde metadados não estão disponíveis. Além disso, avanços recentes com modelos de linguagem pré-treinados e sistemas baseados em *Large Language Models* (LLMs) [Lin et al. 2024] enfrentam críticas por manifestarem vieses políticos nativos de suas arquiteturas e disparidades com a percepeção humana [Lin et al. 2025].

Para mitigar essas limitações, este trabalho propõe uma metodologia para investigar a robustez de modelos baseados em *Deep Metric Learning*. Diferente de abordagens que avaliam o desempenho em dados de domínios conhecidos, esta pesquisa foca

na generalização para fontes não vistas durante o treinamento. Utiliza-se uma arquitetura capaz de identificar vieses ideológicos em fragmentos textuais de veículos de imprensa inéditos, permitindo validar se o modelo extraiu representações semânticas agnósticas ao domínio ou se apenas memorizou padrões superficiais de determinados veículos.

2. Trabalhos Relacionados

A literatura aborda a detecção de viés ideológico sob diversas óticas, desde redes estruturais [Efron 2004] até modelos econômicos de reputação midiática [Gentzkow and Shapiro 2006]. Avanços integraram análise de redes sociais e PLN para quantificar o viés via gráficos de interação [Lin et al. 2011]. Contudo, tais métodos enfrentam limitações severas em documentos com dados esparsos de hiperlinks ou isolados de redes de citação estabelecidas, limitando a capacidade de generalização do modelo.

Alternativamente, metadados de redes sociais, como interações no Twitter [Rao and Spasojevic, 2016; Elejalde et al., 2017] e perfis demográficos de audiência no Facebook [Ribeiro et al., 2018], auxiliam na inferência de inclinação política. Entretanto, essas abordagens são dependentes de APIs de terceiros e restringem-se frequentemente a cenários de alta polarização binária. Tal dependência reforça a necessidade de soluções que operem exclusivamente sobre o conteúdo textual bruto.

No âmbito da análise textual direta, as investigações priorizam a escolha lexical e a recorrência temática como indicadores de inclinação ideológica [Dallmann et al. 2015], empregando mecanismos de atenção para capturar o enquadramento (*framing*) em manchetes [Gangula et al. 2019]. Embora modelos baseados na arquitetura *Transformer*, como o BERT (*Bidirectional Encoder Representations from Transformers*), atinjam elevada precisão em fontes previamente mapeadas, tais estruturas demonstram fragilidade ao processar artigos de domínios inéditos [Baly et al. 2020].

Para mitigar essa lacuna, o framework *POLITICS* [Liu et al. 2022] introduziu o pré-treinamento de modelos RoBERTa via (*triplet loss*), comparando artigos de diferentes espectros sobre a mesma notícia. Esse esforço foi aprimorado por Volf and Simko [2025], que realizaram o ajuste fino (*fine-tuning*) do modelo utilizando múltiplos datasets unificados. Os autores demonstraram que essa especialização, aliada a uma filtragem prévia de textos políticos, é essencial para assegurar a robustez e a generalização dos classificadores em diversos domínios.

Contudo, apesar do desempenho robusto desses modelos especializados, tanto as versões refinadas quanto sistemas baseados em modelos de larga escala, como o *IndiVec* [Lin et al. 2024], estão sujeitos a vieses políticos inerentes ou a falhas de alinhamento com a percepção humana em cenários *zero-shot* [Lin et al. 2025]. Diante dessas limitações, este trabalho propõe o emprego de *Deep Metric Learning* fundamentado na técnica de *semi-hard sampling*. Diferente de abordagens puramente classificatórias, esta estratégia visa otimizar a topologia do espaço de características, forçando o modelo a distinguir nuances ideológicas através de uma amostragem mais informativa. Com isso, busca-se superar os gargalos de generalização dos modelos tradicionais sem incorrer na excessiva complexidade computacional típica de arquiteturas de larga escala.

3. Material e Métodos

A metodologia assume que o viés ideológico se manifesta em padrões discursivos, processando textos via modelos pré-treinados e otimizando *embeddings* por *Contrastive* e *Triplet Loss*. Conforme a Figura 1, o fluxo abrange quatro etapas: definição dos conjuntos de dados, geração de representações por aprendizagem métrica, treinamento de classificadores e análise de desempenho. As seções seguintes detalham cada módulo da arquitetura proposta.

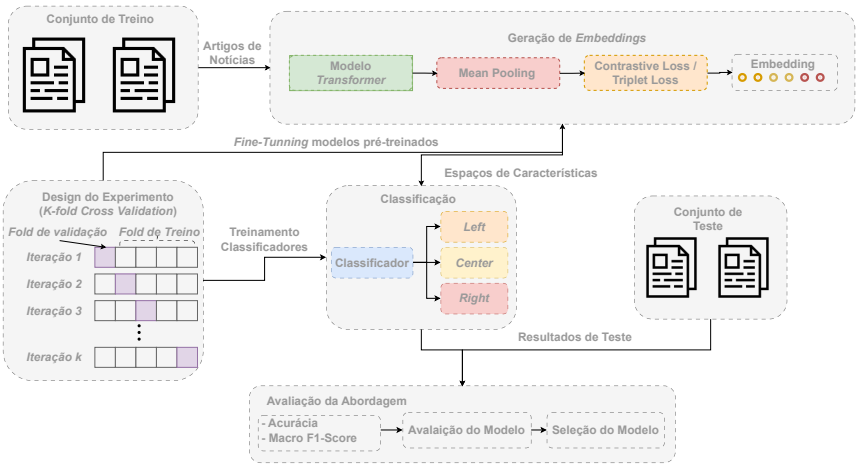

Figura 1. Visão geral do método de detecção de viés ideológico por meio do conteúdo textual de artigos de notícias.

3.1. Dados Experimentais

Para o desenvolvimento deste estudo, utilizaram-se os conjunto de dados detalhados na Tabela 1. O foco principal recai sobre os dados do *Article Bias Prediction* (ABP) [Baly et al. 2020], composto por 37.554 notícias em inglês rotuladas em três categorias: *left, center e right*. A confiabilidade desses rótulos provém da plataforma AllSides[1], que emprega auditorias rigorosas e revisões da comunidade

Tabela 1. Resumo dos conjuntos de dados e volume de amostras.

Conjunto de Dados	Classes	Quantidade
FlipBias [Chen et al. 2018]	Left/Center/Right	3.066
ABP [Baly et al. 2020]	Left/Center/Right	37.554

A robustez metodológica foi validada por dois critérios de particionamento. O primeiro, *media-bias split* (Tabela 2), segrega os artigos de modo que os dados de uma mesma fonte de notícia sejam exclusivos a uma única partição, impedindo que veículos presentes no conjunto de treinamento apareçam na validação ou teste. Essa estratégia é fundamental para mitigar o vazamento de dados e avaliar a capacidade de generalização para fontes não vistas. O segundo, *random split* (Tabela 3), mantém a consistência na distribuição de classes entre treino e validação por meio de uma amostragem aleatória.

[1] `https://www.allsides.com/media-bias/media-bias-rating-methods`

Tabela 2. Estatísticas da partição *media-bias split*.

Treino			Validação			Teste		
Viés	*Total*	*%*	*Viés*	*Total*	*%*	*Viés*	*Total*	*%*
Left	8.861	33,32%	Left	1.640	69,60%	Left	402	30,92%
Center	7.488	28,16%	Center	618	26,23%	Center	299	23,00%
Right	10.241	38,51%	Right	98	4,15%	Right	599	46,07%

Tabela 3. Estatísticas da partição *random split*.

Treino			Validação			Teste		
Viés	*Total*	*%*	*Viés*	*Total*	*%*	*Viés*	*Total*	*%*
Left	9.750	34,84%	Left	2.438	34,84%	Left	402	30,92%
Center	7.988	28,55%	Center	1.998	28,55%	Center	299	23,00%
Right	10.240	36,60%	Right	2.560	36,59%	Right	599	46,07%

Adicionalmente, o experimento foi estendido para um cenário de generalização externa, onde o modelo treinado integralmente no conjunto ABP foi submetido à avaliação no conjunto *FlipBias* [Chen et al. 2018]. Este conjunto contém 2.781 eventos sob múltiplas perspectivas es serve como referência para medir a eficácia das representações em contextos fora do domínio de treinamento, seguindo as mesmas diretrizes estabelecidas por Lin et al. [2025].

3.2. Tarefa de Geração de *Embeddings*

Para a execução da tarefa, foi utilizado um modelo fundamentado no *Bidirectional Encoder Representations from Transformers (BERT)* [Devlin et al. 2018], reconhecidos pela eficácia na modelagem de dependências de longo alcance e na extração de relações semânticas granulares [Zhang and Rao 2020]. A seleção recaiu sobre o DistilRoBERTa [Liu et al. 2019], variante destilada que preserva a robustez da arquitetura original, contudo, apresenta reduções substanciais no custo computacional e nos requisitos de memória.

O modelo *Transformer* processa as sequências de entrada, seguido por uma camada de *Mean Pooling* que consolida as representações em um vetor único. O (*fine-tuning*) é regido por estratégias de aprendizagem métrica[2], utilizando as funções de perda *Contrastive Loss* ou *Triplet Loss*. Tal abordagem assegura que os *embeddings* gerados na saída posicionem instâncias contextualmente similares em regiões próximas do espaço de representação, otimizando a discriminação entre as classes.

No que se refere ao pré-processamento, as *stopwords* foram preservadas, visto que a arquitetura BERT demonstra eficácia na extração de nuances contextuais a partir desses elementos. Por fim, o treinamento foi estabelecido com um limite de 100 épocas, utilizando o otimizador Adam com taxa de aprendizado de 10^{-4} e *batch size* de 16. Para mitigar o *overfitting* e assegurar a capacidade de generalização dos modelos, aplicou-se a técnica de *Early Stopping* com paciência de 5 ciclos, monitorando-se a convergência da função de perda no conjunto de validação.

[2]Aprendizagem métrica (ou *metric learning*) refere-se ao uso de algoritmos para aprender uma função de distância que capture a similaridade entre dados.

3.2.1. Mecanismos de Aproximação e Distanciamento

Nesta abordagem, o codificador (DistilRoBERTa) ajusta os pesos de suas camadas para otimizar a qualidade dos *embeddings* via *Contrastive Loss* e *Triplet Loss*. O objetivo é o aprendizado de representações vetoriais onde instâncias semanticamente similares convirjam no espaço representação, enquanto exemplos dissimilaridades sejam repelidos.

A *Contrastive Loss* é aplicada utilizando a distância Euclidiana sobre pares de exemplos, conforme definido na Equação 1:

$$L = \frac{1}{2}(1-y)D^2 + \frac{1}{2}y\{\max(0, m-D)\}^2 \tag{1}$$

Onde y representa o rótulo binário (0 para similar, 1 para dissimilar), D denota a distância entre as representações e m é a margem de separação.

Complementarmente, a *Triplet Loss* utiliza triplas compostas por uma âncora (a), um exemplo positivo (p) e um negativo (n). O objetivo, expresso na Equação 2, assegura que a distância entre a âncora e o positivo seja inferior à distância entre a âncora e o negativo por uma margem m:

$$L = \max(0, D(a,p) - D(a,n) + m) \tag{2}$$

Para otimizar o aprendizado, empregou-se o *mining* de negativos *semi-hard*. Esses exemplos, que satisfazem a condição $D(a,p) < D(a,n) + m$, fornecem gradientes mais informativos e mitigam o *overfitting* em comparação a negativos *hard* [Kertész 2021]. Esse processo refina a capacidade discriminatória do modelo, permitindo que os *embeddings* capturem relações semânticas profundas, como a ideologia de uma notícia, independentemente da fonte de publicação.

3.3. Tarefa de Classificação: Modelos e Parametrizaçao

Após o mapeamento dos *embeddings*, onde a proximidade entre os vetores reflete a similaridade ideológica das notícias. A classificação dos artigos foi realizada por meio de três algoritmos: *K-Nearest Neighbors (KNN)*, *K-Means* e *Multilayer Perceptron (MLP)*. O *KNN* e o *K-Means* foram utilizados para explorar a organização dos dados por vizinhaça e agrupamento, respectivamente. Para o *KNN*, aplicou-se um *grid search* sistemático para otimização de hiperparâmetros, variando o número de vizinhos (k) entre $5, 10, 15, 20, 25$ e 30. Já o *K-Means* foi configurado com o número de *clusters* equivalente às classes presentes no conjunto de dados ABP.

A rede *MLP* foi estruturada com duas camadas densas (512 e 256 neurônios). Adotou-se a função de ativação *ReLU* para garantir um treinamento mais rápido e estável [Zhang and Rao 2020], enquanto a camada de saída utilizou a *softmax* para a classificação final. O modelo otimizado com o algoritmo *Adam* e a função de perda *Categorical Cross-Entropy*, escolhas consolidadas na literatura para problemas multiclasse [Goodfellow et al. 2016].

A confiabilidade do experimento foi assegurada pela validação cruzada *k-folds*, utilizando 5 *folds* . Esse procedimento garante que a proporção das classes seja mantida

em todas as etapas, evitando resultados enviesados e permitindo medir com precisão a capacidade do modelo em classificar novos dados [Brink et al. 2016].

3.4. Avaliação de Desempenho

O desempenho dos modelos de classificação será avaliado pelas métricas de Acurácia e *Macro F1-score*. A Acurácia (Equação 3) fornece uma medida geral da taxa de acerto para o conjunto de classes C. Complementarmente, o *Macro F1-score* (Equação 4) permite uma avaliação equilibrada entre as classes, mitigando distorções causadas por eventuais desbalanceamento no conjunto de dados.

As métricas são formalmente definidas conforme segue:

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3) \qquad \text{Macro } F1 = \frac{1}{|C|} \sum_{c \in C} F1_c \quad (4)$$

Em que $F1_c$ representa a média harmônica entre a Precisão (P_c) e a Revocação (R_c) para cada classe:

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \quad F1_c = 2 \times \frac{P_c \times R_c}{P_c + R_c} \quad (5)$$

Neste contexto, TP, TN, FP e FN representam, respectivamente, os verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

A validação da hipótese de pesquisa — de que o discurso textual reflete o viés ideológico — dar-se-á mediante a obtenção de altos índices em ambas as métricas. Espera-se que valores elevados de *Macro F1-score* confirmem a capacidade discriminatória do modelo entre as diferentes vertentes ideológicas, assegurando que o desempenho não seja reflexo de uma classe majoritária no conjunto de dados.

3.5. Ambiente de Execução

A linguagem Python, com as bibliotecas NumPy, Pandas, Scikit-Learn e PyTorch, foi a ferramenta primária para implementação e avaliação dos modelos. Os experimentos ocorreram em um servidor equipado com processador Intel Xeon W-2235, 128 GB de RAM e GPU NVIDIA RTX 8000 (48 GB VRAM), visando a aceleração em hardware.

4. Resultados e Discussão

Para a tarefa de geração de *embeddings*, a análise do espaço de representação via t-SNE[3] na Figura 2 permite compreender como as diferentes funções de perda estruturam as representações do modelo DistilRoBERTa. O comparativo revela que a *Contrastive Loss* (Figura 2a) gera agrupamentos visivelmente mais densos e com fronteiras de separação nítidas entre as classes ideológicas. Em contrapartida, o mapeamento via *Triplet Loss* (Figura 2b) apresenta maior dispersão e zonas de sobreposição entre os *clusters*, o que compromete a precisão dos modelos de aprendizagem em cenários de maior complexidade.

[3]Configuração do t-SNE: número de componentes=3, perplexidade=30, iterações=1000, métrica=euclidiana.

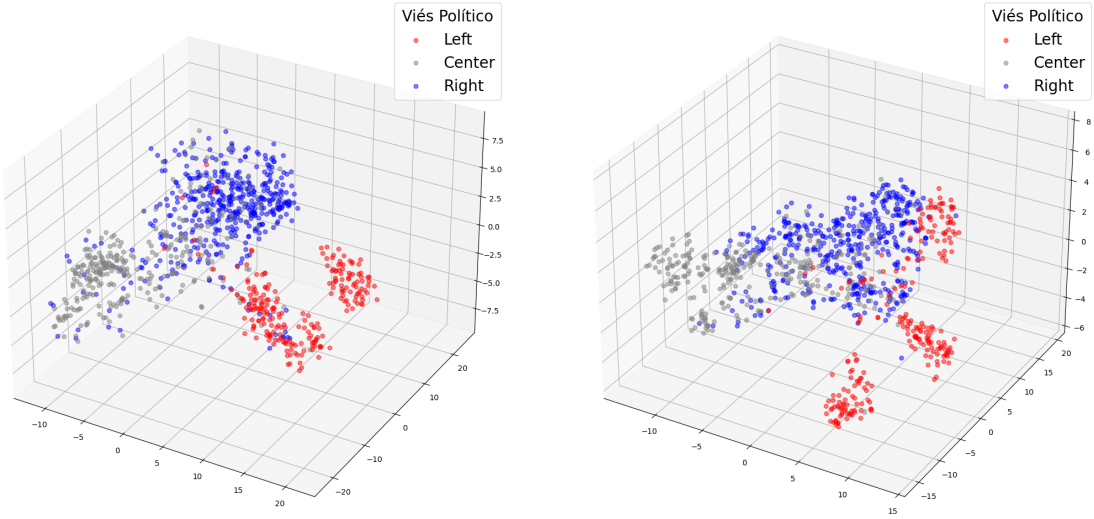

(a) ***Contrastive Loss*** **com DistilRoBERTa.** **(b)** ***Triplet Loss*** **com DistilRoBERTa.**

Figura 2. Distribuição dos *embeddings* via t-SNE no conjunto de teste do ABP. O comparativo demonstra a separação das classes entre as funções de perda *Contrastive* e *Triplet Loss*.

Em relação a tarefa de classificação de viés ideológico, cujos resultados encontram-se sintetizados nas Tabelas 4 e 5, as métricas observadas no cenário *random split* montram-se superiores àquelas obtidas via *media-bias split*, uma consequência direta da maior homogeneidade na distribuição dos dados de treinamento. Na partição *media-bias split*, o modelo fundamentado em MLP com *contrastive Loss* atingiu o maior *Macro F1-score* com 0.43, evidenciando uma estruturaçao à abordagem via *Triplet Loss*

Tabela 4. Desempenho dos modelos treinados no conjunto ABP (media split) e avaliados no FlipBias, comparando as funções de perda Contrastive (C) e Triplet (T). AM: ABP media split; DR: DistilRoBERTa; MF1: Macro F1-Score; Acc: Acurácia; Rec: Revocação; Prec: Precisão.

		ABP Media-bias				FLIPBIAS			
Perda	**Modelos**	**MF1**	**Acc**	**Rec**	**Prec**	**MF1**	**Acc**	**Rec**	**Prec**
Contrastive	AM-DR-C-KNN	0.31	0.31	0.36	0.36	0.24	0.28	0.28	0.30
	AM-DR-C-MLP	**0.43**	0.43	**0.49**	**0.47**	0.29	0.32	0.32	0.46
	AM-DR-C-kmeans	0.21	0.46	0.33	0.15	**0.41**	**0.43**	**0.43**	**0.56**
Triplet	AM-DR-T-KNN	0.23	0.25	0.30	0.31	0.34	0.42	0.42	0.38
	AM-DR-T-MLP	0.34	0.36	0.40	0.39	0.28	0.35	0.35	0.38
	AM-DR-T-kmeans	0.36	**0.50**	0.41	0.33	0.39	0.40	0.40	0.53

No tocante à generalização para o conjunto *FlipBias*, os resultados dispostos revelam que o algoritmo *K-means* obteve o melhor desempenho relativo em ambos os cenários de treinamento. O emprego de variados classificadores permitiu observar que, apesar das discrepâncias nominais, os modelos mantêm certa equivalência no tocante à precisão em bases externas, sugerindo estabilidade nas fronteiras de decisão extraídas, Nesse contexto, a configuração baseada em *Contrastive Loss* com *K-means* consolidou-se como a abor-

dagem mais robusta, apresentando índices de *Macro F1-score* de 0.41 e 0.48 consistentes frente à diversidade das amostras de dados.

Tabela 5. Desempenho dos modelos treinados no conjunto ABP (random split) e avaliados no FlipBias, comparando as funções de perda Contrastive (C) e Triplet (T). AR: ABP random split; DR: DistilRoBERTa; MF1: Macro F1-Score; Acc: Acurácia; Rec: Revocação; Prec: Precisão.

		ABP Random				FLIPBIAS			
Perda	**Modelos**	**MF1**	**Acc**	**Rec**	**Prec**	**MF1**	**Acc**	**Rec**	**Prec**
Contrastive	AR-DR-C-KNN	0.83	0.83	0.84	0.83	0.41	0.41	0.41	0.50
	AR-DR-C-MLP	0.80	0.80	0.82	0.79	0.42	0.42	0.42	0.48
	AR-DR-C-kmeans	**0.83**	**0.83**	0.83	**0.85**	**0.48**	0.47	**0.48**	**0.51**
Triplet	AR-DR-T-KNN	**0.83**	**0.83**	**0.85**	0.83	0.47	**0.48**	**0.48**	0.50
	AR-DR-T-MLP	0.83	0.83	0.84	0.83	0.43	0.45	0.45	0.50
	AR-DR-T-kmeans	0.79	0.79	0.82	0.78	0.38	0.48	0.48	0.37

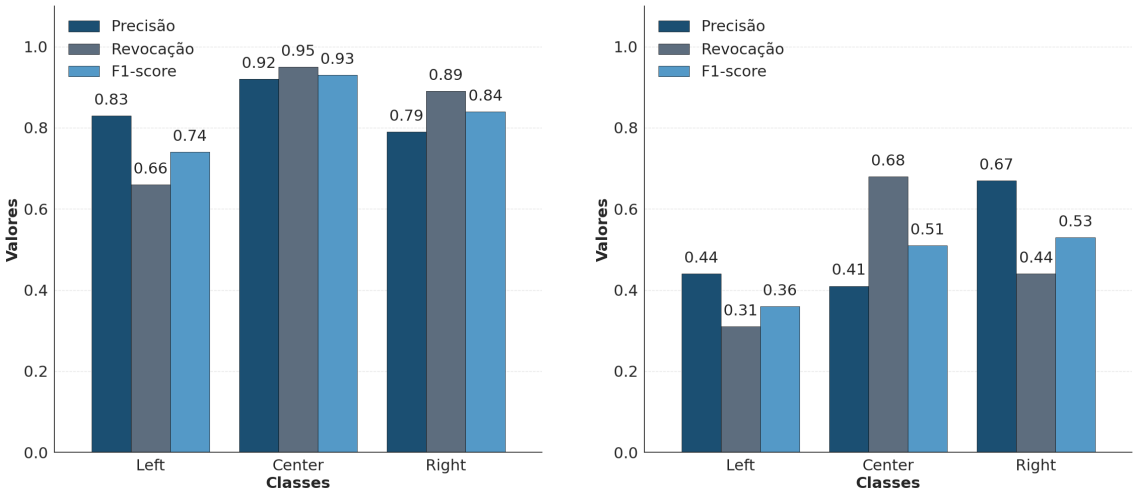

(a) AR-DR-C-KMEANS no ABP. **(b) AR-DR-C-KMEANS no FlipBias.**

Figura 3. Resultados das métricas de precisão, acurácia e macro f1-score por classe para o modelo AR-DR-C-KMEANS avaliado nos conjuntos de dados ABP e FlipBias.

Essa robustez global, contudo, manifesta-se de forma heterogênea quando analisada sob a ótica das métricas por classe. A análise qualitativa do desempenho da melhor configuração experimental (AR-DR-C-KMEANS) no conjunto FlipBias revela que o modelo apresenta uma queda crítica de revocação na classe *left*, atingindo apenas 0.31. Esse fenômeno indica que o modelo, embora preciso ao identificar o viés progressista quando este segue os padrões léxicos do conjunto do ABP (onde obtém 0.83 de precisão), falha em reconhecer as mesmas inclinações em fontes inéditas. Isso sugere que o discurso da classe *left* no FlipBias pode utilizar enquadramentos ou termos que o codificador DistilRoBERTa interpretou como neutros ou conservadores, evidenciando que a aprendizagem métrica, sozinha, não elimina a dependência de padrões discursivos específicos do domínio de treinamento. Além de evidenciar o desafio de transpor o aprendizado entre ecossitemas de notícias distintos.

4.1. Desempenho de Generalizacao

A Tabela 6 demonstra que modelos treinados no FlipBias apresentam desempenho sólido no domínio de origem, com o classificador *KNN* atingindo 0.81 de *Macro F1-Score*. Contudo, observa-se uma queda drástica de eficácia ao testar na base do ABP, onde o melhor resultado cai para 0.41. Esse cenário indica que, embora a *Contrastive Loss* auxilie na extração de representações úteis, a generalização entre diferentes conjuntos de dados de viés midiático permanece um desafio crítico para arquiteturas baseadas em DistilRoBERTa.

Tabela 6. Desempenho dos modelos treinados no conjunto FlipBias e avaliados no ABP. F: FlipBias; DR: DistilRoBERTa; C: Contrastive Loss; MF1: Macro F1-Score; ACC: Acurácia; Rec: Revocação; Prec: Precisão.

		FLIPBIAS				ABP			
Dados	**Modelos**	**MF1**	**Acc**	**Rec**	**Prec**	**F1**	**Acc**	**Rec**	**Prec**
	F-DR-C-KNN	**0.81**	**0.80**	**0.81**	**0.81**	**0.41**	**0.47**	**0.44**	**0.41**
FLIPBIAS	F-DR-C-MLP	0.81	0.80	0.81	0.81	0.26	0.32	0.37	0.24
	F-DR-C-kmeans	0.78	0.77	0.77	0.79	0.35	0.53	0.41	0.34

Tabela 7. Comparativo de desempenho entre os baselines e os experimentos nos conjuntos FLIPBIAS e ABP. MF1: Macro F1-Score, ACC: Acurácia.

	FLIPBIAS		ABP	
Modelos	**MF1**	**Acc**	**MF1**	**Acc**
[Baly et al. 2020]	-	-	0.80	0.79
AR-DR-C-kmeans	0.48	0.47	0.83	0.83
F-DR-C-KNN	**0,81**	0.80	0.41	0.47
[Lin et al. 2025]	0.51	**0.89**	0.63	0.62
[Volf and Simko 2025]	0.53	0.56	**0.84**	**0.84**

Ao comparar esses experimentos com os baselines na Tabela 7, nota-se que o modelo AR-DR-C-kmeans apresenta um desempenho competitivo no conjunto ABP, alcançando 0.83 de *Macro F1-Score* e acurácia. O desempenho superior deste modelo em relação ao trabalho de [Baly et al. 2020] sugere que o agrupamento via *k-means* é eficaz para capturar estruturas de viés em dados específicos. No entanto, o modelo de Volf e Simko [2025] detém os melhores índices para o conjunto ABP, com 0.84 em ambas as métricas. Por outro lado, no conjunto Flipbias, o modelo F-DR-C-KNN destaca-se como o melhor classificador entre todos os comparados, atingindo 0.81 de *Macro F1-Score*. Essa discrepância reforça que a escolha do conjunto de treinamento e a especialização do modelo ditam a confiabilidade da detecção em diferentes domínios.

Por fim, a Tabela 8 revela que as LLMs em regime *zero-shot* ainda não superam os modelos especializados. O Mistral atinge a maior acurácia de 0.84, mas seu baixo *Macro F1-Score* de 0.55, aponta para uma dificuldade em equilibrar as classes, enquanto o GPT-3.5 exibe instabilidade severa com apenas 0.15 de acurácia. Em concordância com [Lin et al. 2025], conclui-se que as LLMs possuem vieses inerentes que distorcem a

Tabela 8. Comparativo de desempenho entre os experimentos e LLMs no conjunto FLIPBIAS. MF1: Macro F1-Score, ACC: Acurácia.

Modelos	Versão	Estratégia	MF1	Acc
AR-DR-C-kmeans	-	-	0.48	0.47
F-DR-C-KNN	-	-	**0.81**	0.80
LLaMa2	Llama-2-7B-Chat	Zero-shot	0.52	0.69
Mistral	Mistral-7B-v0.1	Zero-shot	0.55	**0.84**
GPT-3.5	gpt-3.5-turbo	Zero-shot	0.39	0.15

percepção de neutralidade, tornando os modelos ajustados com perdas contrastivas ferramentas mais precisas e imparciais.

5. Considerações Finais

Este trabalho teve por objetivo investigar a detecção de viés ideológico via aprendizagem métrica (*Contrastive* e *Triplet Loss*). Os resultados mostraram que modelo proposto, AR-DR-C-Kmeans, atingiu 0.83 de *Macro F1-Score* no conjunto ABP, demonstrando alternativa competitividade e robustez na generalização entre diferentes domínios. Em relação às LLMs, os experimentos indicaram que modelos em *zero-shot* enfrentam dificuldades em equilibrar precisão em domínios políticos complexos, apresentando vieses inerentes que distorcem a percepção de neutralidade, conforme [Lin et al. 2025].

Como trabalhos futuros, pretende-se explorar técnicas de adaptação de domínio, além de estratégias de *fine-tuning*, *few-shot prompting* e *Retrieval-Augmented Generation*. Essas abordagens visam unir a precisão de modelos especialistas à versatilidade das LLMs para discernir nuances ideológicas sutis.

Referências

Baly, R., Da San Martino, G., Glass, J., and Nakov, P. (2020). We can detect your bias: Predicting the political ideology of news articles. In *Proc. of EMNLP*, pages 4982–4991.

Brink, H., Richards, J., and Fetherolf, M. (2016). *Real-World Machine Learning*. Manning Publications.

Chen, W., Wachsmuth, H., Khatib, K., and Stein, B. (2018). Learning to flip the bias of news headlines. In *Proc. of INLG*, pages 79–88.

Chiang, C. and Knight, B. (2011). Media bias and influence: Evidence from newspaper endorsements. *The Review of Economic Studies*, 78:795–820.

Dallmann, A., Lemmerich, F., Zoller, D., and Hotho, A. (2015). Media bias in german online newspapers. In *Proc. of HT*, pages 133–137.

Devlin, J., Chang, M., Lee, K., and Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*.

Efron, M. (2004). The liberal media and right-wing conspiracies. In *Proc. of ACM CIKM*, pages 390–398.

Gangula, R., Duggenpudi, S., and Mamidi, R. (2019). Detecting political bias in news articles using headline attention. In *Proc. of ACL BlackboxNLP*, pages 77–84.

Gentzkow, M. and Shapiro, J. M. (2006). Media bias and reputation. *Journal of Political Economy*, 114:280–316.

Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press.

Kertész, G. (2021). Different triplet sampling techniques for lossless triplet loss on metric similarity learning. In *Proc. of IEEE SAMI*, pages 449–454.

Lin, L., Wang, L., Guo, J., and Wong, K. (2025). Investigating bias in llm-based bias detection: Disparities between llms and human perception. In *Proc. of COLING*, pages 10634–10649.

Lin, L., Wang, L., Zhao, X., Li, J., and Wong, K. (2024). Indivec: An exploration of leveraging llms for media bias detection. *arXiv preprint arXiv:2402.00345*.

Lin, Y., Bagrow, J., and Lazer, D. (2011). More voices than ever? quantifying media bias in networks. In *Proc. of ICWSM*, volume 5.

Liu, Y. et al. (2019). Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*.

Liu, Y., Zhang, X., Wegsman, D., Beauchamp, N., and Wang, L. (2022). Politics: Pre-training with same-story article comparison for ideology prediction. In *Findings of NAACL*, pages 1354–1374.

Patricia Aires, V., Nakamura, F., and Nakamura, E. (2019). A link-based approach to detect media bias in news websites. In *Companion Proc. of WWW*, pages 742–745.

Spinde, T. et al. (2021). Neural media bias detection using distant supervision with babe. In *Findings of EMNLP*, pages 1166–1177.

Volf, M. and Simko, J. (2025). Political leaning and politicalness classification of texts. *arXiv preprint 2507.13913*.

Zhang, Y. and Rao, Z. (2020). Deep neural networks with pre-train model bert for aspect-level sentiments classification. In *Proc. of IEEE ITOEC*, pages 923–927.